

题目：轻量化的上下文感知逻辑结构恢复

作者：Po-Wei Huang, Abhinav Ramesh

Kashyap, 覃彦霞 (Yanxia Qin) , 杨亚静 (Yajing Yang) , Min-Yen

Kan (通讯作者) ; 单位：新加坡国立大学；邮箱：{huangpowei, abhinav, qinyx, yang0317, kanmy}@comp.nus.edu.sg

摘要：科学论文的逻辑结构恢复任务，旨在把文本与文章的语义章节对应起来。以往工作往往把每一行“孤立地”分类，忽略该行的上下文。本文在基于Transformer 的科学文档处理流程之上，加入“行级注意力”，显式建模跨行上下文；并结合损失函数工程与半监督学习中的数据增强，使分类性能较近期 SOTA 提升约 10%。我们仅用纯文本特征与更少的数据，即达到了与使用字体/空间位置等丰富文档特征的方法相当的效果，从而形成轻量的训练管线。

引言：在科学文档处理（SDP）中，逻辑结构恢复提供了基础信息。文档的“逻辑结构”指示其构成的标签层级（Mao 等，2003；Luong 等，2010）。恢复该结构有助于理解长篇论文，并支持抽象式摘要、元数据抽取、信息抽取等下游任务。

该任务把论文中的文本行归入预定义语义类别（见表1），表示各自扮演的角色（Ramesh Kashyap & Kan, 2020）。既往研究通常忽略该行的上下文；也有工作借助字体类型、文本位置等富特征（Luong 等，2010；Rahman & Finin, 2019），但这依赖 OCR 等外部系统，流程繁琐且易出错。问题是：不依赖这些富特征，能否取得相当的表现？

注：中文逐页逐段翻译，图表/公式版式未复刻。

我们的回答是一种既简洁又稳健的纯文本模型：不引入版面/图像等额外特征，而是更好地建模邻近行语境，捕捉文档逻辑的延续性，并利用大量未标注数据。

做法一：把多行断行文本视为“跨行上下文”，在 Transformer (Vaswani 等, 2017 ; Devlin 等, 2019) 之上引入局部注意力 (Yang 等, 2016 ; Beltagy 等, 2020) ，得到对上下文敏感的句向量。

做法二：采用半监督学习 (Xie 等, 2020 ; Sohn 等, 2020) 充分利用未标注数据，缓解标注稀缺。

做法三：借鉴 UDA (Xie 等, 2020) 等框架的损失工程元素，即便在纯监督训练下也能增益，从而形成轻量训练流程。

尽管仅用纯文本训练，我们的模型表现接近使用富文本特征的当前方法；进一步加入半监督后，在宏平均 F1 上相对 SOTA 提升约 10%。

2 相关工作

除正文之外，先前研究还会提取字号、字形、分段等“富文本信息”，因为这些往往是判别文档逻辑结构的关键线索（Rahman & Finin, 2019）。例如 SectLabel（Luong 等, 2010）先用 OCR 获取富文本，再用 CRF（Lafferty 等, 2001）把提取文本分类为预定义标签。Tao 等（2014）进一步把空间度量、排版、极少量文本模式与上下文意义结合到二维 CRF 中。

也有工作使用文本数据中残存的视觉线索（换行、缩进、对齐等）来增强逻辑结构抽取，并以随机森林为主模型（Koreeda & Manning, 2021）。

另一条路径是直接利用页面布局与图像：基于 R-CNN 的检测模型（Ren 等, 2015；He 等, 2017；Cai & Vasconcelos, 2018）以 PDF 的“截图”作为输入来捕获结构；LayoutLM 系列（Xu 等, 2020, 2021；Huang 等, 2022）把对象检测与文本 Transformer 融合，并加入页面上的位置嵌入；DiT（Li 等, 2022）以 ViT（Dosovitskiy 等, 2021）为骨干做图像层面的结构检测。

尽管普遍会结合富文本信息，也存在仅用纯文本的工具，如 SciWING（Ramesh Kashyap & Kan, 2020）。这类方法输入简单、流水线精简。与 SciWING

对每行的简单表示不同，我们显式引入跨行上下文，并利用丰富的未标注数据。

3 上下文模型构建

我们遵循 Luong 等（2010）的任务设定，对论文的每一行进行逻辑结构分类。方法完全基于文本，结合现代 NLP 模型与训练技术，以实现更轻量的方案。我们把任务建模为逐行分类，以保留边距断行的概念，而无需引入布局或空间信息。给定长度为 n 的文档 $D = \{\ell_1, \dots, \ell_n\}$ ，目标是把每一行 ℓ_i 分类到 Luong 等（2010）定义的 23 个类别之一。

3.1 基线模型：我们使用 SciWING 的逻辑结构分类器作为基线。其以纯文本为输入，使用 ELMo 与双向 LSTM 为每行单独生成句向量，并进行线性分类。

3.2 行级注意力：与基线不同，我们显式考虑邻近行的上下文，因为逻辑结构往往跨越多行。引入上下文可减少在大段同类结构内部的误判。我们改造层次注意力网络（HAN）：选用能直接产生上下文敏感句向量的编码器，省去词级编码与词级注意力；然后在编码器与分类器之间加入“行级注意力层”，用于跨行建模（见图1）。

为兼顾效率，我们采用类似 Longformer 的滑动窗口注意力。对目标行 ℓ_i ，把其上下各 d 行堆叠成 K/V ，目标行作为 Q ，经多头注意力得到上下文增强的表示 ℓ'_i ；再与原 ℓ_i 拼接送入分类器。

3.3 基于 Transformer 的句向量：使用 BERT、SciBERT、Sentence-BERT、RoBERTa 等，并比较三种汇聚策略：[CLS]、均值池化、注意力池化。

4 半监督学习：监督需要足够标注；在 SDP 领域标注稀缺，SSL 结合未标注可更优。

4.1 预备符号：设 X 为 B 个标注样本批； U 为 μB 个未标注样本批； $\hat{y}(x)$ 为预测分布； H 为交叉熵； D 为 KL 散度； A/α 表示强/弱增强。

数据增强：图像领域弱增强（翻转裁剪）与强增强（RandAugment、CTAugment）可注入有效且多样的噪声。

文本领域：采用回译作为强增强，既保留语义又改变写法；弱增强借助 EDA（同义替换、插入、交换、删除）模拟。

4.2 框架：UDA 用一致性训练正则化未标注数据；标注部分计算交叉熵 L_s ，未标注部分对强增强样本与原样本的一致性计算 L_u ，总损失 $L=L_s+\lambda L_u$ 。

FixMatch：标注部分对“弱增强后样本”算交叉熵；未标注部分对“强增强样本 vs. 弱增强伪标签”算交叉熵，仅当置信度 $>\tau$ 时纳入。

4.3 损失工程

TSA：设置随训练进度上升的阈值，仅对“最高概率低于阈值”的样本计入损失，优先学习不自信样本，缓解不平衡。三种日程：指数、线性、对数。

SDA：把一致性损失用于监督场景——同批输入原样本与增强样本，增强样本做一致性损失、原样本做交叉熵，并在交叉熵上叠加 TSA。

5 实验

数据：采用 SectLabel (20 ACL + 20 ACM)。为适配滑动窗口，我们按论文级重划：4 验证/4 测试/32 训练，避免邻近行泄漏。另构建“扩展测试集”：随机选 20 篇 ACL 2020 论文人工标注，形成轻度域外评测；半监督未标注集由 ACL2021 与 NeurIPS2021 构成，并用 EDA/回译增强。指标：宏 F1。

结果：RoBERTa+滑动注意力优于 SciWING；叠加 TSA 与 UDA/SDA 后，SectLabel 测试集最高提升约 10%，UDA 提升了扩展测试集的泛化。

6 分析：分结构与训练两方面逐步加组件评估。

6.1 滑动窗口注意力

窗口=1/3/5/7 与“5（空洞）”对比：窗口=5

综合最好；过大引入噪声，空洞采样会跳过仅一行的结构导致连续性差。

6.2 BERT 与池化

uncased 模型显著较差；SBERT

不适合按排版断行的数据；RoBERTa +

注意力池化最佳；未观察到稳定的“池化×模型”相关。

6.3 半监督

FixMatch

在原分割上最高；UDA+对数日程在域外更鲁棒；去弱增强会过拟合伪标签。

UDA 的训练过程：指数日程早期信号少、收敛慢，且一致性损失易放大初误差；对数日程更强调未标注数据，若多样则更鲁棒，有利跨域。半监督提升整体，但因伪标签继承偏置，少数类收益有限。

6.4 损失工程

仅监督场景下：指数日程往往低于基线；线性/对数更优，因为更早提升阈值、强调不自信样本；加入一致性损失会放大日程影响，在对数日程略优，在扩展集上需防过拟合。TSA 能缓解不平衡并逼近半监督，但域外鲁棒性仍逊于半监督。

6.5 与多模态模型比较

LayoutLM/v2

把坐标与图像嵌入并入表示，参数更大、推理更慢、批大小更小；LayoutLM 系列本质是文本 Transformer + 图像骨干的“组装模型”。DiT 仍需 OCR 作为依赖。本文提供纯文本、上下文驱动的轻量替代。

7 结论

有效利用多行上下文后，纯文本逻辑结构恢复可接近富特征方法。我们用 Transformer 句向量 + 滑动窗口注意力，并通过 TSA/SDA/半监督进一步优化。未来需研究在不破坏序列结构的前提下缓解类别不均衡。

本页包含：不同退火日程的监督训练曲线；文本-仅与多模态模型的参数规模/模态/是否含图像骨干的对比；以及在单张 RTX3090 上的最大批大小对比（文本-仅模型批次更大；LayoutLMv2 在本设定下发生内存错误）。

参考文献（起始）：列出 SciBERT、Longformer、Mix/Remix/FixMatch、RandAugment、BERT、ViT、回译等文献。为便于检索，本译本不逐条译名。

参考文献（续）：包括

EDA、LayoutLM/v2、Sentence-BERT、Faster

R-CNN、TSA/UDA 与更多条目；请以原文为准进行准确引用。